

机器学习作业 1-线性判别分析 LDA

2150248-姚天亮-自动化

一、作业要求

用 Python 编程实现线性判别分析 LDA，并给出下面数据集上的结果及说明。

二、原理说明

线性判别分析(Linear Discriminant Analysis, LDA)是一种有监督的降维和分类技术。LDA 的目标是在保留类别间的尽可能多的差异的同时，降低类别内部的差异，从而获得较好的分类效果。希望最大化投影后类别间投影点的离散程度，同时最小化投影后同类别内部投影点的离散程度。

给定训练样例集，将样例投影到一条直线上，使得同类样例的投影点尽可能接近、异类样例的投影点尽可能远离；在对新样本进行分类时，将其投影到同样的这条直线上，再根据投影点的位置来确定样本的类别。

给定数据集 $D = \{(x_i, y_i)\}_{i=1}^m, y_i \in \{0, 1\}$ ，令 X_i, μ_i, Σ_i 分别表示第 $i \in \{0, 1\}$ 类示例的集合、均值向量、协方差矩阵。若将数据投影到直线 w 上，则两类样本的中心在直线上的投影分别为 $w^T \mu_0$ 和 $w^T \mu_1$ ；若将所有样本点都投影到直线上，则两类样本的协方差分别为 $w^T \Sigma_0 w$ 和 $w^T \Sigma_1 w$ ，由于直线是一维空间，因此上述协方差与投影均为实数。

欲使同类样例的投影点尽可能接近，可以让同类样例投影点的协方差尽可能小，即 $w^T \Sigma_0 w + w^T \Sigma_1 w$ 尽可能小；而欲使异类样例的投影点尽可能远离，可以让类中心之间的距离尽可能大，即 $\|w^T \mu_0 - w^T \mu_1\|_2^2$ 尽可能大。同时考虑二者，则可得到欲最大化的目标：

$$J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w}$$

定义“类内散度矩阵”

$$\begin{aligned} S_w &= \Sigma_0 + \Sigma_1 \\ &= \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T \end{aligned}$$

以及“类间散度矩阵”

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

则 J 可以改写为

$$J = \frac{w^T S_b w}{w^T S_w w}$$

该式即为最大化目标。

注意到 J 的分子和分母都是关于 w 的二次项因此 J 的解与 w 的长度无关,只与其方向有关。不失一般性, 令 $w^T \mu_0 w = 1$, 则 J 等价于

$$\begin{aligned} \min_w \quad & -w^T S_b w \\ \text{s.t.} \quad & w^T S_w w = 1 \end{aligned}$$

由拉格朗日乘法, 上式等价于

$$S_b w = \lambda S_w w$$

其中 λ 是拉格朗日乘子.注意到 $S_b w$ 的方向恒为 $\mu_0 - \mu_1$, 不妨令

$$S_b w = \lambda(\mu_0 - \mu_1)$$

代入知


$$w = S_w^{-1}(\mu_0 - \mu_1)$$

考虑到数值解的稳定性, 在实践中通常是对 S_w 进行奇异值分解, 即 $S_w = U \Sigma V^T$, 这里 Σ 是一个实对角矩阵, 其对角线上的元素是 S_w 的奇异值, 然后, 再由 $S_w^{-1} = V \Sigma^{-1} U^{-1}$ 得到 S_w^{-1} , 同时, LDA 可从贝叶斯决策理论的角度来阐释, 并可证明, 当两类数据同先验、满足高斯分布且协方差相等时, LDA 可达到最优分类。

可以将 LDA 推广到多分类任务中.假定存在 N 个类, 且第 i 类示例数为 m_i 叫"我们先定义"全局散度矩阵"

$$\begin{aligned} S_t &= S_b + S_w \\ &= \sum_{i=1}^m (x_i - \mu)(x_i - \mu)^T \end{aligned}$$

三、实验结果



```
LDA Coefficients (Weights):  
[[ -2.29448249 -10.89707109]]  
  
LDA Mean vectors:  
[[0.57133333 0.27122222]  
 [0.49533333 0.15344444]]  
  
Classification Threshold: 0.728906743264478  
Linear Discriminant Analysis Score: 0.7222222222222222
```

心得

通过这次实践，我深刻理解了 LDA 的原理和目标。LDA 旨在最大化类别间的差异，最小化类别内部的差异，从而获得良好的分类效果。这种思路非常巧妙，充分利用了数据的标签信息。

在实现过程中，我还了解到 LDA 背后的数学原理，包括类内散布矩阵、类间散布矩阵以及广义特征值问题的求解。这些数学概念虽然抽象，但在算法中发挥着关键作用。

另一方面，我也意识到 LDA 的局限性。LDA 假设数据服从高斯分布，并且只能学习线性判别边界。因此，对于非线性可分的数据，LDA 可能无法取得良好的效果。此时，我们需要使用其他更加复杂的非线性降维和分类方法。

这次作业让我对 LDA 算法有了更深入的理解，同时也激发了我去学习其他机器学习算法的兴趣。我期待在后续的学习中，能够掌握更多实用的算法和技术，为解决实际问题做好充分准备。